Uso de autoencoder para comprimir PDFs de redshifts de galáxias

Gabriel Teixeira

Work in progress




Sumário

- Introdução Redshifts
- Obtenção das PDFs
- Problemáticas
- Compactação de PDFs inteiras
- Compactação de geradores
- Ideias futuras




Redshifts

- Redshifts são medidas que mostram o quanto uma galáxia está se afastando de nós.
- Podemos obter o valor de redshift de uma galáxia através do seu espectro luminoso.




$$z=rac{\lambda-\lambda_o}{\lambda_o}$$




Redshifts fotométricos

- Diferente da espectroscopia, aqui estamos interessados na magnitude em determinadas bandas do espectro.
- As magnitudes são medidas através de filtros.
- Redshifts fotométricos também são chamados de photo-z





The Southern Photometric Local Universe Survey (S-PLUS): improved SEDs, morphologies and redshifts with 12 optical filters - astro-ph.GA, 2 sep 2019



Como foram obtidos os photo-z's *


- Utilizando dados espectroscópicos e fotométricos do Legacy Survey DR9 (região coberta pelo DELVE Survey DR2)
- ❖ Magnitudes das bandas g, r, z, w1 e w2





100 011 1010 100 0110001 100 101010 1010 01 101

Como foram obtidos os photo-z's *



*Para o presente trabalho

Problemas


- O catálogo fotométrico do DELVE cobre uma área >20.000deg², possuindo ~17.000deg² com cobertura g,r,i,z
- ~10% dos dados disponíveis correspondem a aproximadamente 200,000,000 objetos

```
>>> fitsfile = Table(train_data['pdf'][:1000, :999])
>>> fitsfile.write('1000PDFs_Table', format='fits', overwrite=True)
~$ du -hs 1000PDFs_Table
7,8M 1000PDFs_Table
```

PDFs desses mesmos ~10% então corresponderiam a aproximadamente 1.5 T de armazenamento em disco

Dataset e Pré-processamento

- PDFs geradas pelo modelo MDN
 - 647981 objetos para treino
 - > 71862 para validação
 - > 503606 para teste



Input:


PDF dividida pela soma de todas as entradas de cada (valores de 0 a 1)


Output:

PDF reconstruída. Saída de uma softmax, valores de 0 a 1

011C001 1C0 10101C 1010 01 101 01 1C00101

Metodologia - Autoencoder





Resultados - Métricas

Point-like Metrics

 $\delta z = z_{phot}^{_{
m Dias}} - z_{spec}^{_{
m Dias}}$

dispersão


$$\sigma_{NMAD} = 1.48 imes mediana(rac{|\delta z - mediana(\delta z)|}{1 + z_{spec}})$$

median bias

 $median(\delta z)$

outlier fraction

$$\eta=rac{|\delta z|}{1+z_{spec}}>0.15$$



PDFs Metrics

PITT

$$PIT = \int_0^{z_{spec}} dz \; PDF(z)$$


Odds


$$Odds = \int_{z^-}^{z_+} dz \ PDF(z)$$


kullback-leibler divergence


 $z_{\pm}=z_{spec}\pm0.06$

$$D(P_1,P_2)=\int dz P_1(z)log(rac{P_1(z)}{P_2(z)})$$











Resultados - Metricas




Conclusões - PDF Autoencoder

- O método é promissor, porém ainda apresenta divergências relevantes para redshifts mais altos
- As reconstruções das métricas são muito similares entre si para os diferentes valores de L (possível mínimo local?)
- Se utilizássemos a compactação para L=20 o espaço estimado de 1.5 T se reduziria a 30 G


```
~$ du -hs 20Values_Table
168K 20Values Table
```



Compactação dos geradores das PDFs




C. R. Bom et al.



Loss -> MSE Épocas -> 30 Batch -> 256

Resultados 175000 (MSE 0.00010 50000 125000 60000 -100000 75000 40000 20000 50000 -10000 25000 α σ epoch Mean PDF 0.50

Resultados - Metricas



Conclusões - Components Autoencoder

- De fato a ideia de compactar os geradores das PDFs melhora o comportamento das mesmas em alto redshift
- Conseguimos lidar com o problema de precisar de um domínio para definir a PDF
- Obtivemos PDFs mais próximas das originais ao compactar os geradores
- Divergência entre as medidas de PIT ainda precisam ser investigadas mais a fundo



Ideias Futuras

- Utilizar camadas convolucionais (1D) no primeiro método
- Estudar e reforçar a robustez dos métodos com cross validation
- Testar formas de pré-processar os geradores de PDF
- Testar a implementação da divergência KBL como loss function!

0110001

100 101010

1010 01 101

011000101

01 10101000

Podemos treinar com muito mais dados !!

Referências

- [1] LIMA, Erik V. R. Photometric redshifts for S-PLUS using machine learning techniques, 2019.
- [2] Christopher M Bishop. Mixture density networks. 1994.
- [3] https://datalab.noirlab.edu/query.php?name=delve_dr2.photoz
- [4] C R Bom, B M O Fraga et al., Developing a victorious strategy to the second strong gravitational lensing data challenge, *Monthly Notices of the Royal Astronomical Society*, Volume 515, Issue 4, October 2022, Pages 5121–5134, https://doi.org/10.1093/mnras/stac2047
- [5] Divergência de Kullback-Leibler: Uma aplicação à Modelagem , Jéssica Franco Cançado Richard, Departamento de Estatística

100 101010

011000101

[6] - https://github.com/cdebom/AstroStatistic2021class/tree/main/02 PDF comp