

# Modelagem de Lentes Gravitacionais Com Normalizing Flows

Métodos em Grande Volume de Dados e Astroinformática

Professor: Clécio Roque de Bom

Aluno: Vitor Souza Ramos

A dark blue diagonal gradient bar that starts from the bottom left and extends towards the top right, covering the lower half of the slide.

# Introdução

- Deformação do espaço-tempo por objetos massivos causa deflexão na luz de objetos mais distantes
- Permitem estudo da distribuição de massa em galáxias (ligado a matéria escura), medições de  $H_0$ , telescópios gravitacionais (Alto redshift), etc.
- Surveys futuros (Euclid, LSST) esperam detectar grande quantidade destes sistemas
- Análise automatizada e rápida é muito importante para a ciência feita com essa informação




Imagem: [https://en.wikipedia.org/wiki/Strong\\_gravitational\\_lensing](https://en.wikipedia.org/wiki/Strong_gravitational_lensing)

# Metodologia – Simulation-Based Inference

- Teorema de Bayes: 
$$P(\theta|X) = \frac{P(\theta)P(X|\theta)}{P(X)}$$
- Likelihood é intratável  $\rightarrow$  Simulation-Based Inference (SBI)
- SBI: Substituímos a likelihood por um simulador que toma parâmetros  $\theta$  do prior e gera as simulações (imagens)
- Sequential Neural Posterior Estimation (SNPE): Treinamos um Estimador de Densidade para aprender a relação entre a imagem simulada e seus parâmetros
- Inferência: Mostramos a imagem ao estimador de densidade e retiramos amostras dos parâmetros calculados para reconstruir uma distribuição posterior

# Metodologia – Normalizing Flows

- Normalizing Flows são uma classe de Estimadores de Densidade
- Transformações inversíveis que são usadas para mapear uma distribuição de probabilidade simples (ex. gaussiana) para uma distribuição mais complexa
- Obtemos a distribuição transformada usando a Fórmula de Mudança de variáveis
- Boas escolhas de Flows: Estratégias para transformações expressivas e tratáveis (determinante fácil de calcular)

$$z \sim p(z)$$

$$x = F(z) = f_n \circ f_{n-1} \circ \dots \circ f_1$$

$$p(x) = p(F^{-1}(x)) \left| \det \frac{\partial F^{-1}(x)}{\partial x} \right|$$

$$p(x) = p(z) |\det J_{z,x}|$$

# Metodologia – Normalizing Flows

- Masked Autoregressive Flows (MAF):

$$Z^D = \{z_1, z_2, \dots, z_D\}$$

$$x_i = h(z_i : \Theta)$$

$$\Theta \sim NN(z_{1:i-1})$$

- Jacobiano é matriz triangular inferior, determinante é produto da diagonal principal

- Neural Spline Flows (NSF):


- Mapeamento de input  $\rightarrow$  Sigmoid
- Espaço dividido em K intervalos (splines)
- Transformação por spline
- Alta expressividade mantendo autoregressividade

$$z_i \rightarrow [0, 1]$$

$$x_i = h^k(z_i : \Theta^K)$$

# Implementação – Gerando Imagens

- Dataset gerado com pacote deeplensstronomy → 10 mil imagens
  - Resolução 64x64
  - 3 bandas (g, r, i)
  - Configurações do Survey Delve
- Priors escolhidos para gerar imagens
- Treinamento
  - Feito com 90% das imagens, 10% para teste
  - Imagens normalizadas




$$\sigma_v \sim \mathcal{U}(150, 400)$$

$$e_1 \sim \mathcal{U}(-0.4, 0.4)$$

$$e_2 \sim \mathcal{U}(-0.4, 0.4)$$

$$z_l \sim \mathcal{U}(0.2, 0.4)$$

$$z_s \sim \mathcal{U}(0.6, 0.8)$$



# Implementação – Workflow

- Pacote sbi: Implementação de SNPE, MAF e NSF
- Definimos uma Embedding Net → 16 features
- Escolhemos o tipo de Estimador de Densidade → MAF ou NSF
  - Quantidade de transformações → 4
  - Hidden Units → 128
- Definimos Método de Inferência → SNPE
- Treinamento:
  - Learning Rate:  $5e-4$
  - Batch size: 50
  - Otimizador: Adam
  - Paciência: 20 épocas
  - Fração de validação: 10%
- Resultado: Gerador de amostras do Posterior → 5000 amostras

Layer (type)	Output Shape	Param #
Conv2d-1	[-1, 8, 64, 64]	224
ReLU-2	[-1, 8, 64, 64]	0
MaxPool2d-3	[-1, 8, 32, 32]	0
Conv2d-4	[-1, 16, 32, 32]	1,168
ReLU-5	[-1, 16, 32, 32]	0
MaxPool2d-6	[-1, 16, 16, 16]	0
Conv2d-7	[-1, 32, 16, 16]	4,640
ReLU-8	[-1, 32, 16, 16]	0
MaxPool2d-9	[-1, 32, 8, 8]	0
Linear-10	[-1, 32]	65,568
ReLU-11	[-1, 32]	0
Linear-12	[-1, 16]	528
ReLU-13	[-1, 16]	0
FCEmbedding-14	[-1, 16]	0
Total params: 72,128		
Trainable params: 72,128		
Non-trainable params: 0		
Input size (MB): 0.05		
Forward/backward pass size (MB): 0.99		
Params size (MB): 0.28		
Estimated Total Size (MB): 1.31		

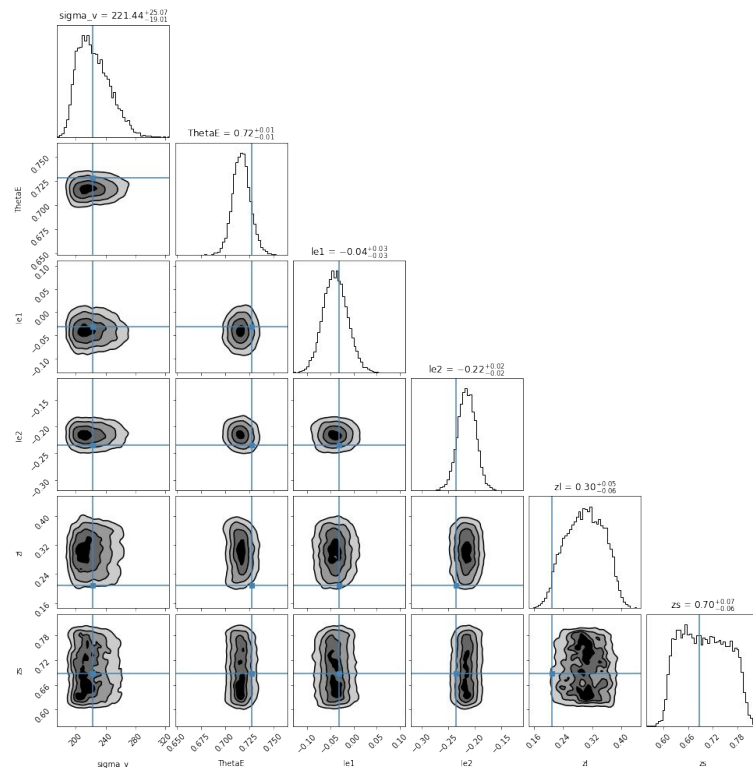

# Implementação – Métricas de Avaliação

- Para uma imagem isolada:
  - Corner Plot
- Para o dataset de teste como um todo:
  - Plot 1x1
  - Resíduo
  - $R^2$
- Consideração sobre resultados
  - Imagens reais indisponíveis
  - Diversas funcionalidades não exploradas do simulador
  - Exposição do método e avaliação da capacidade de modelar uma distribuição de probabilidade

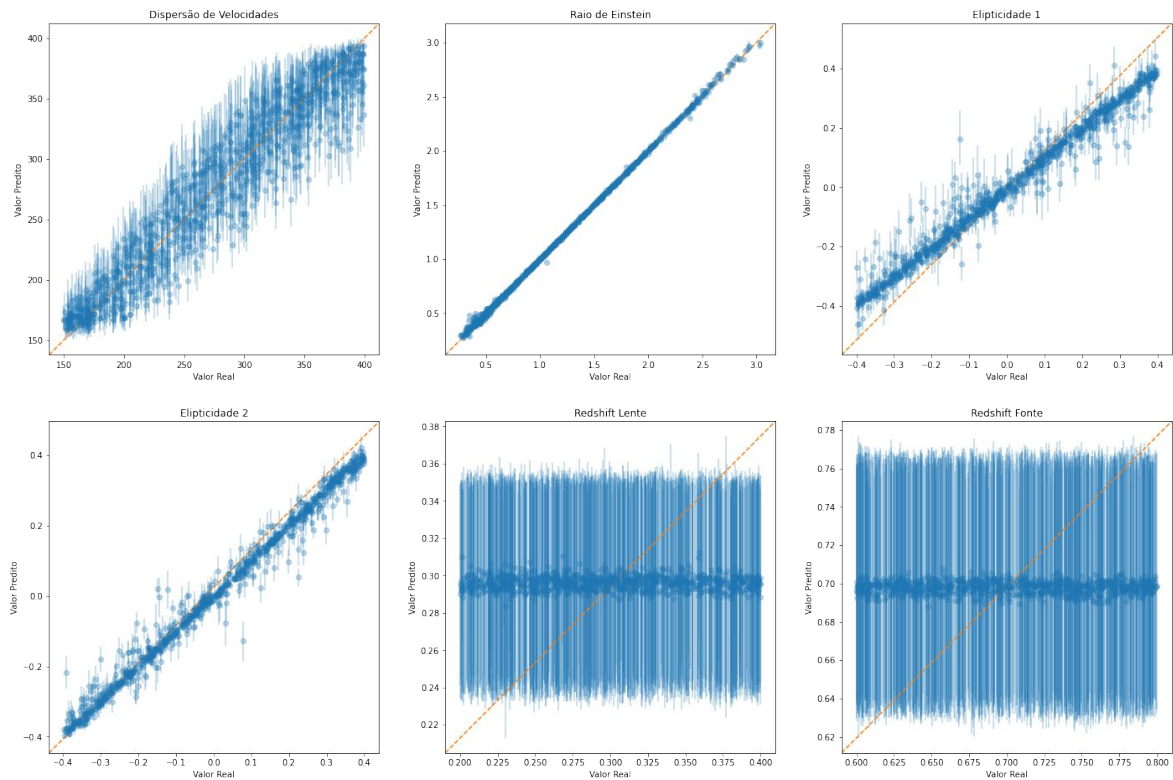


# Resultados – MAF

- Treinamento
  - 202 épocas
  - Aprox. 8 minutos




# Resultados – MAF



$R^2$	
$\sigma_v$	0.903
$\theta_E$	0.999
$e_1$	0.976
$e_2$	0.987
$z_l$	-0.007
$z_s$	-0.006

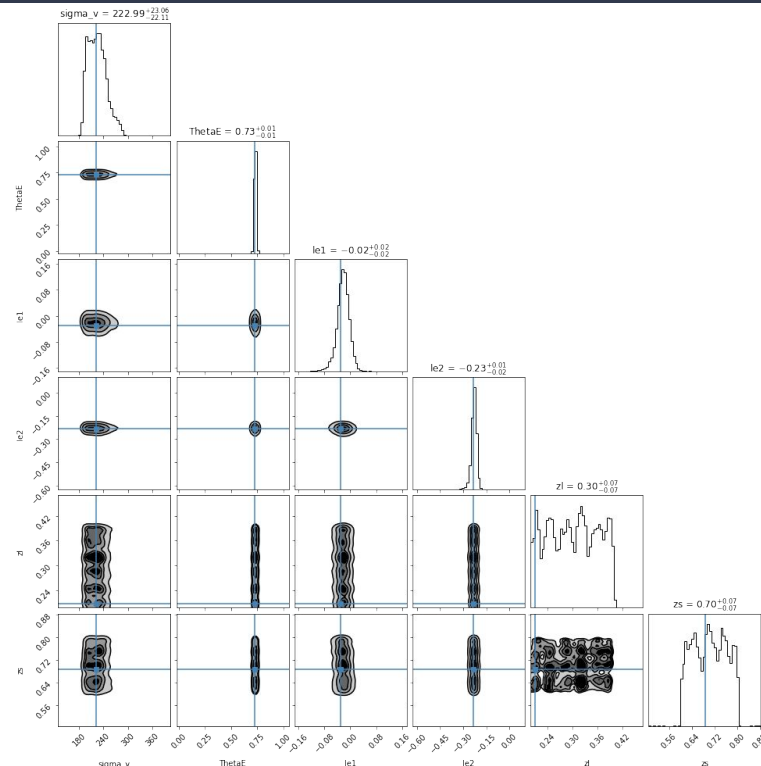
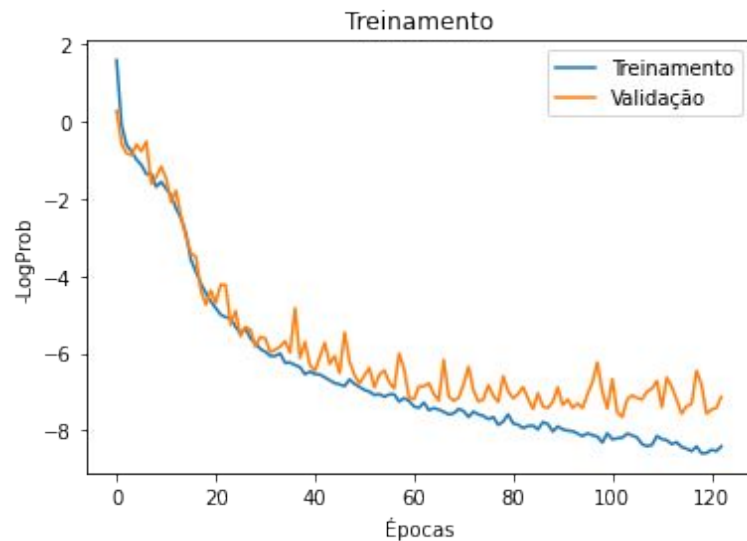
# Resultados – MAF



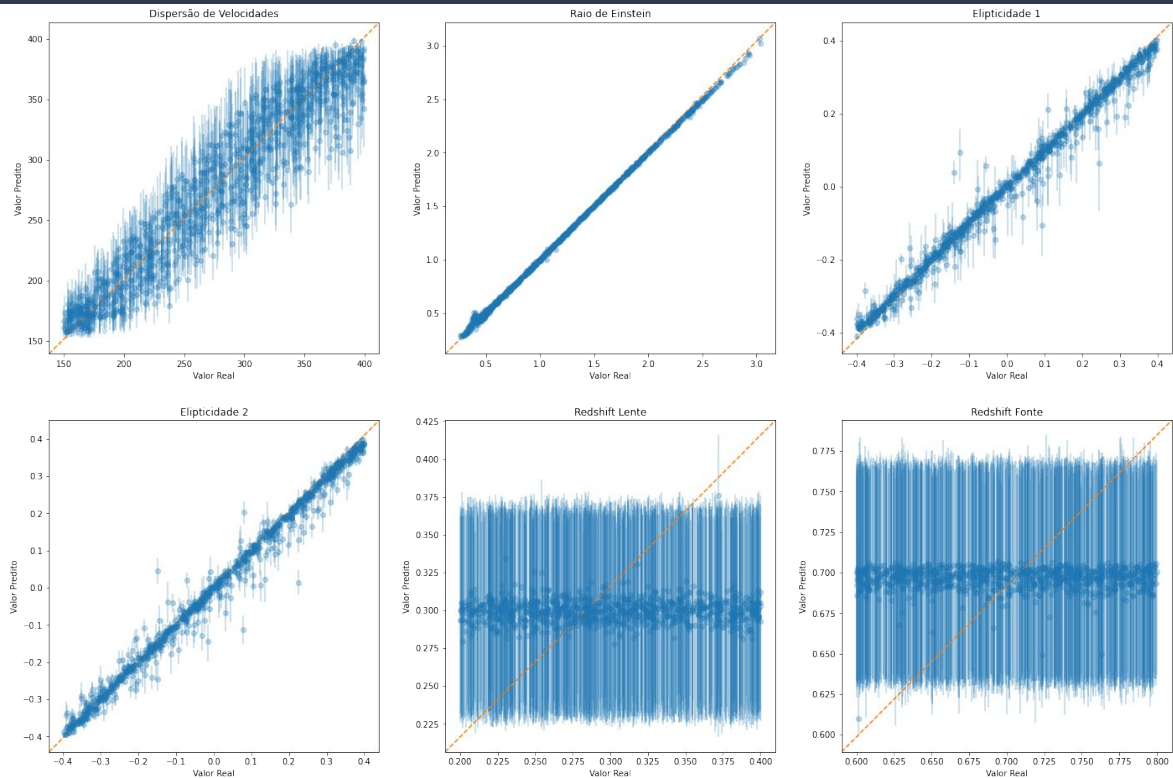
Resíduo Abs. Médio	
$\sigma_v$	0.067
$\theta_E$	0.014
$e_1$	0.269
$e_2$	0.179
$z_l$	0.171
$z_s$	0.0742

# Resultados – NSF

- Treinamento
  - 123 épocas
  - Aprox. 15 minutos




# Resultados – NSF



$R^2$	
$\sigma_v$	0.902
$\theta_E$	0.999
$e_1$	0.988
$e_2$	0.988
$z_l$	-0.008
$z_s$	-0.012

# Resultados – NSF



Resíduo Abs. Médio	
$\sigma_v$	0.068
$\theta_E$	0.014
$e_1$	0.204
$e_2$	0.173
$z_l$	0.173
$z_s$	0.074

# Conclusão

- Os dois estimadores de densidade foram capazes de aprender a modelar bem o raio de Einstein
- MAF teve viés nas elipticidades, NSF foi mais expressivo
- Apesar da alta variação a dispersão de velocidades também é razoavelmente bem modelada
- NSF demora mais para treinar, mas evitou erro viés nas elipticidades
- Nenhum dos dois Estimadores de Densidade foi capaz de modelar os redshifts → Possível falha nas simulações
- NSF revisitado → 16 Transf., 512 H.U.: Resultados similares
- Possibilidades Futuras
  - Investigar simulações
  - Exploração de outros métodos de inferência (SNLE, SNRE)
  - Outros tipos de transformações (MDN)
  - Aplicação de modelos a imagens reais

# Referências

1. [\[1911.01429\] The frontier of simulation-based inference](#)
2. [\[1908.09257\] Normalizing Flows: An Introduction and Review of Current Methods](#)
3. [\[1505.05770\] Variational Inference with Normalizing Flows](#)
4. [\[1905.07488\] Automatic Posterior Transformation for Likelihood-Free Inference](#)
5. [\[1705.07057\] Masked Autoregressive Flow for Density Estimation](#)
6. [\[1906.04032\] Neural Spline Flows](#)
7. [\[1502.03509\] MADE: Masked Autoencoder for Distribution Estimation](#)
8. [\[2102.02830\] deepnstronomy: A dataset simulation package for strong gravitational lensing](#)
9. [\[1911.06341\] Deep Learning in Wide-field Surveys: Fast Analysis of Strong Lenses in Ground-based Cosmic Experiments](#)
10. [\[2210.10793\] LeMoN: Lens Modelling with Neural networks -- I. Automated modelling of strong gravitational lenses with Bayesian Neural Networks](#)



# Referências

- 11 [\[2205.09126\] Estimating the warm dark matter mass from strong lensing images with truncated marginal neural ratio estimation](#)
- 12 Simulation-Based Inference of Strong Gravitational Lensing Parameters - <https://arxiv.org/abs/2112.05278>
- 13 Strong Lensing Parameter Estimation on Ground-Based Imaging Data Using Simulation-Based Inference - <https://arxiv.org/abs/2211.05836>
- 14 Normalizing Flows for Probabilistic Modeling and Inference - <https://arxiv.org/abs/1912.02762>
- 15 Pacote sbi - <https://www.mackelab.org/sbi>
- 16 [https://akosiorek.github.io/ml/2018/04/03/norm\\_flows.html](https://akosiorek.github.io/ml/2018/04/03/norm_flows.html)